Bootcamp Data · Epitech

USAGE D'INSTAGRAM ET BIEN-ÊTRE_

< Rush 4 · Segmentation des utilisateurs />

Jordy · Manon D. · Manon R. · Mina · Tom

Soutenance · 15 minutes

< Le déroulé />

LE PLAN

01 **Les données**
Quel fichier croire, un nettoyage sans perte

02 **Les hypothèses non concluantes**
Sommeil, activité physique, pays

03 **Les hypothèses concluantes**
Temps passé, bonheur, âge, habitudes

04 **La segmentation**
Méthode, 24 segments, critères, nouvel utilisateur

05 **Protection des données · RGPD**
Variables autorisées, santé, mineurs

06 **Les limites**
Ce que nos données ne permettent pas d'affirmer

07 **Recommandations**
Trois actions pour les équipes produit

< 01 · Les données />

DEUX VERSIONS DU FICHIER, UN CHOIX DOCUMENTÉ

Quel fichier croire ?

- Mêmes 200 000 utilisateurs, 52 colonnes sur 58 identiques.
- Toutes les colonnes que nous utilisons sont identiques : nous travaillons sur le fichier « usage ».
- Emploi et heures de travail : nous croyons le fichier « users », qui corrige 45 % de 13–17 ans « salariés à temps plein ».

Un nettoyage sans perte

- Aucune valeur manquante, aucun doublon.
- 26 % des lignes ont une incohérence métier : signalées, pas supprimées.
- Sans elles, le temps passé explique toujours 71 % du stress : résultats inchangés.
- Trois variables écartées : app_name constante, pas quasi constants, durée de session = minutes ÷ sessions.

< 02 · Les hypothèses non concluantes />

TROIS PISTES SANS LIEN AVEC L'USAGE

Sommeil

≈ 7 h

par nuit, et 17 % de petits dormeurs, dans tous les segments de temps passé

Source : info.gouv.fr, 2025

Activité physique

≈ 8 000 pas

par jour, et 7,1 à 7,2 h de sport par semaine, dans tous les segments

Source : Ameli

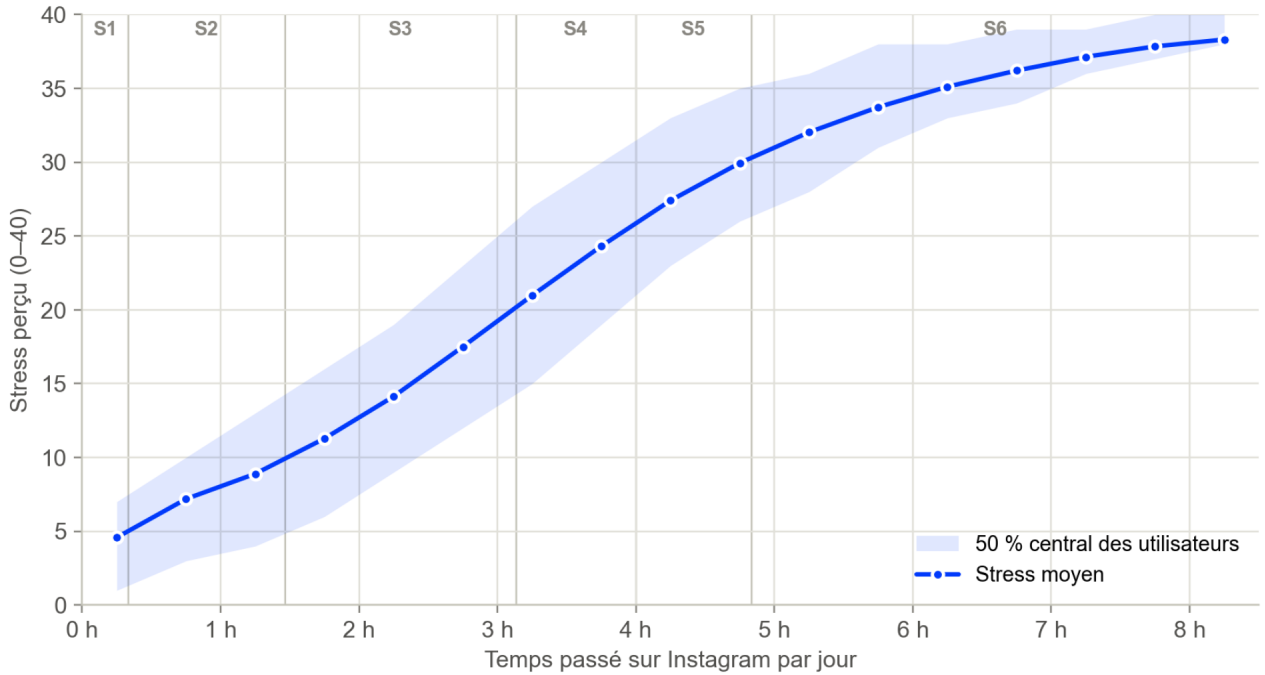
Pays

19,9 à 20,3

de stress moyen dans les 9 pays et le groupe « Autres pays », pour le même temps passé

Un indicateur sans lien avec l'usage est aussi un résultat. Nos sources attendaient un effet du sommeil et du sport : c'est une limite de la réplique synthétique.

LE STRESS MONTE AVEC LE TEMPS PASSÉ



Légende : stress moyen (0–40) par tranche de 30 minutes · zone bleue : la moitié centrale des utilisateurs · lignes : limites des segments S1 à S6

+5,4 pts

de stress par heure passée sur Instagram, sur une échelle de 0 à 40

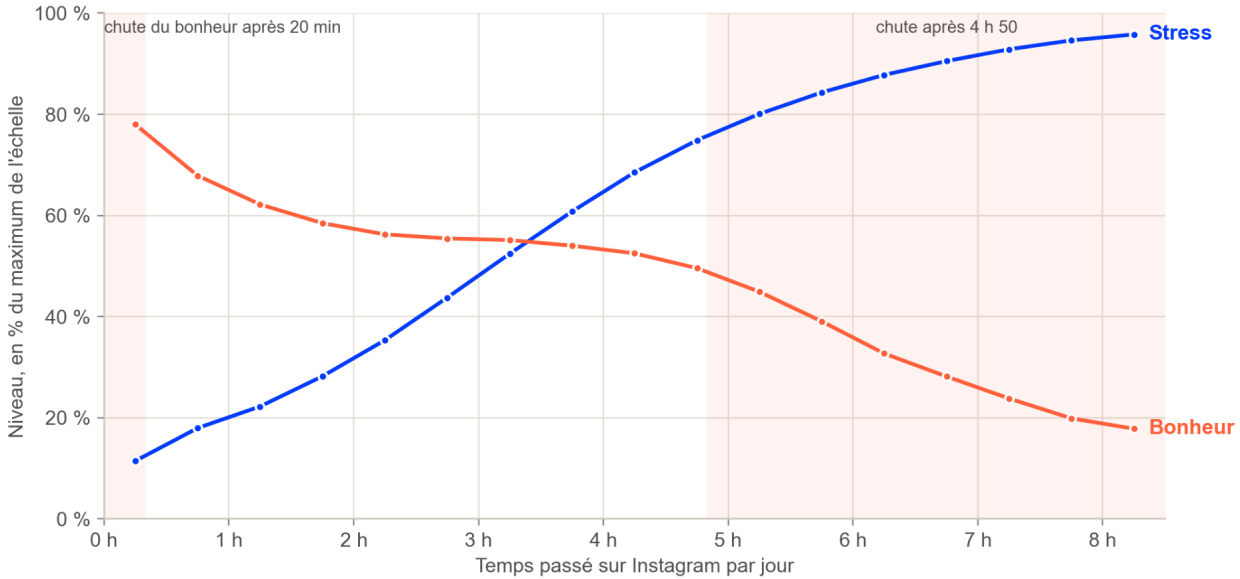
71 %

des écarts de stress expliqués par le temps passé, à lui seul

0 % → 89 %

d'utilisateurs en stress élevé, du segment S1 au segment S6

LE BONHEUR BAISSE SURTOUT AUX DEUX EXTRÊMES



Légende : moyennes par tranche de 30 minutes, ramenées sur une même échelle : stress sur 40 (en bleu), bonheur sur 10 (en orange) · zones colorées : les deux chutes du bonheur

16 %

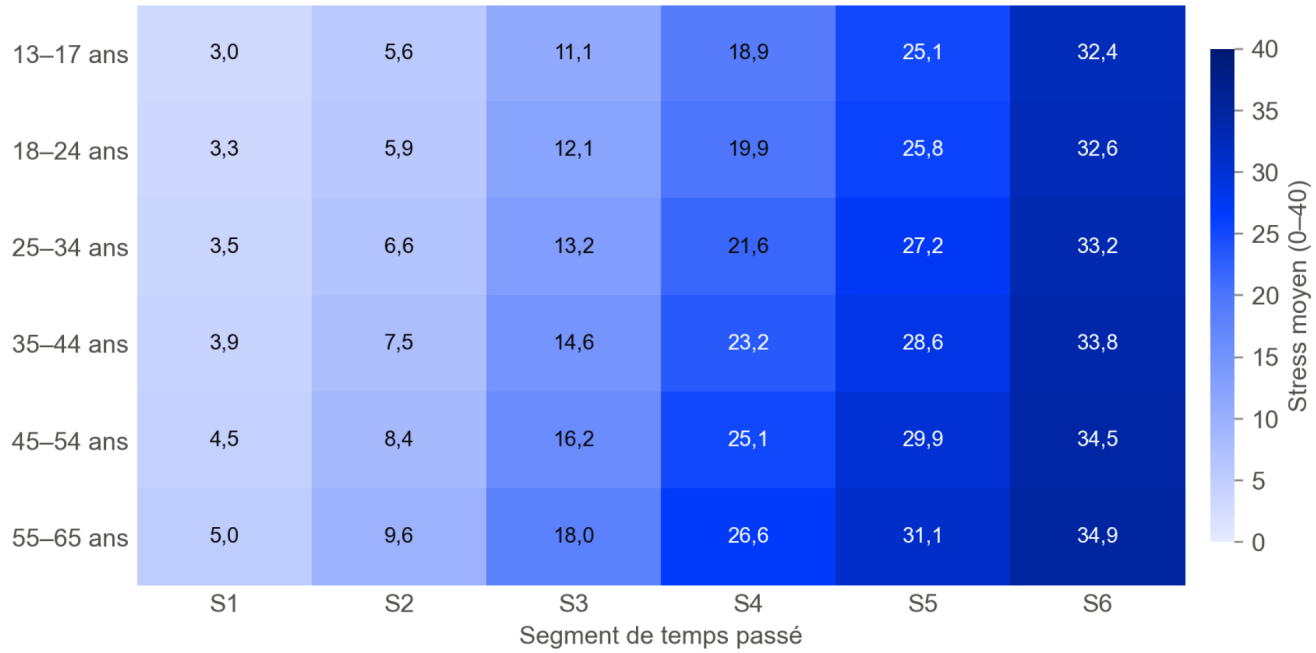
des écarts de bonheur expliqués par le temps passé, contre 71 % pour le stress

20 min · 4 h 50

les deux seuils où le bonheur chute

Pour les équipes produit : suivre le stress et le bonheur séparément.

À USAGE ÉGAL, LES PLUS ÂGÉS SONT PLUS STRESSÉS



Légende : stress moyen (0–40) par tranche d'âge et par segment de temps passé · plus la case est foncée, plus le stress est élevé · lire chaque colonne de haut en bas

18,9 → 26,6

stress moyen en S4 (188 à 240 min par jour), des 13–17 ans aux 55–65 ans

+1,2 pt

de stress par tranche de 10 ans, à temps passé égal

63 % · 43 %

des 13–17 ans et des 55–65 ans passent 3 h ou plus par jour : les plus jeunes sont les plus exposés

LES MOINS HEUREUX ET LES PLUS STRESSÉS ONT UN USAGE PLUS INTENSIF

Comparaison	Indicateur	Écart brut	À temps passé égal
Moins heureux / plus heureux	sessions par jour	+85 %	+1 %
Créateurs / consommateurs	bonheur (1–10)	−1,0 point	0,0 point (à âge égal aussi)
Activité la plus privée / la plus publique	stress (0–40)	−12,5 points	0,0 point
Profil réflexe / profil immersion	stress (0–40)	+10,2 points	+0,4 point

À temps passé égal : la même comparaison, entre utilisateurs qui passent le même temps sur Instagram (par tranches de 10 minutes).

< 04 · La segmentation />

DES PALIERS DE TEMPS PLUTÔT QU'UN CLUSTERING

La voie choisie : **prédire le bien-être à partir de l'usage**, sous la forme de paliers de temps passé croisés avec l'âge.

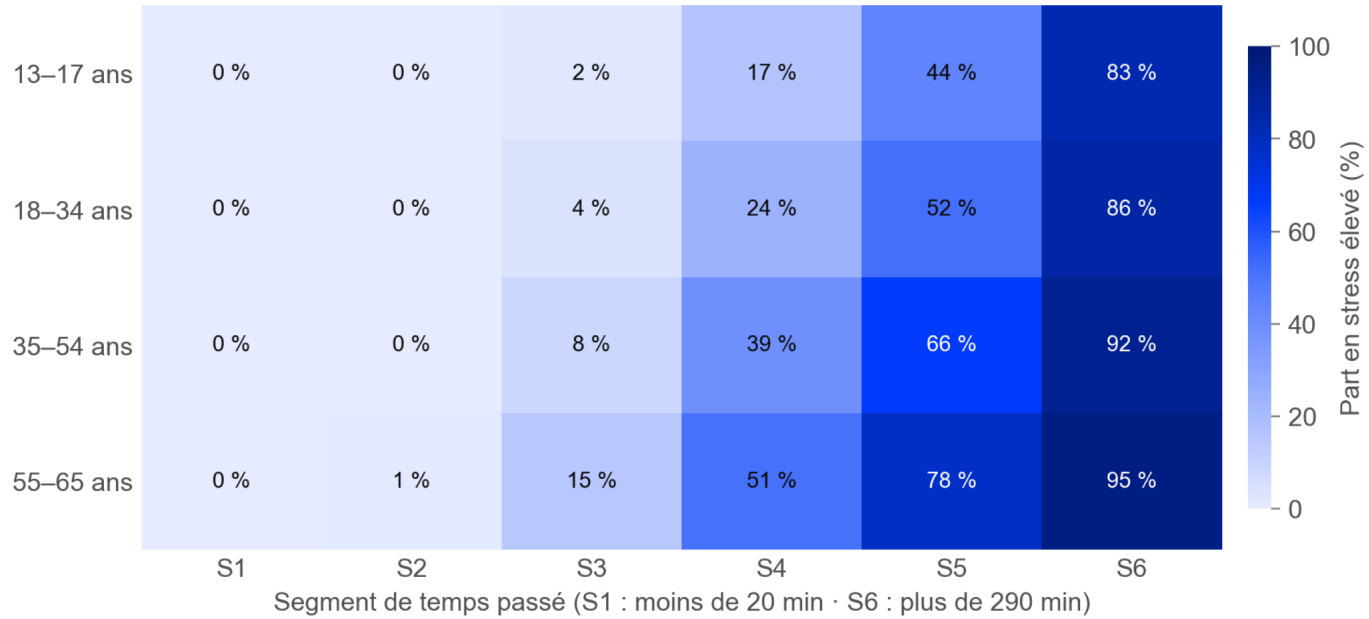
Un clustering…

- retrouverait surtout le temps passé : les compteurs d'activité en sont presque des copies (corrélations de 0,84 à 0,98) ;
- n'y ajouterait rien : à temps passé égal, les habitudes d'utilisation n'apportent rien (partie 03) ;
- donnerait des groupes difficiles à expliquer, qui peuvent changer d'une exécution à l'autre.

Nos segments…

- séparent le stress et le bonheur, avec des seuils placés là où ils changent (20 min, 4 h 50) ;
- se lisent sans aide : « S4 Soutenu · 55–65 ans » ;
- s'appliquent à tout utilisateur, sans donnée de santé ;
- se calculent en une seule passe sur les 200 000 utilisateurs.

24 SEGMENTS : TEMPS PASSÉ × ÂGE



Légende : part des utilisateurs en stress élevé (27 ou plus sur 40) dans chaque segment · S1 : moins de 20 min par jour, S6 : plus de 290 min

Ce qu'elle ajoute au classement par temps passé

DES SEUILS

où le bien-être bascule : 20 min et 4 h 50 par jour

L'ÂGE

en S4, 17 % des 13–17 ans en stress élevé, contre 51 % des 55–65 ans

< 04 · La segmentation />

SIX CRITÈRES, TOUS VÉRIFIÉS SUR LES DONNÉES

Critère	Mesure	Résultat
1. Distingue bien le bien-être	Part en stress élevé, du segment le plus bas au plus haut	de 0 % à 95 %
2. Apporte plus que le temps seul	Plus grand écart entre groupes d'âge dans un même segment de temps	34,6 points (S4 Soutenu)
3. S'applique à tout utilisateur	Valeurs manquantes dans l'âge et le temps passé	0
4. Est stable	Plus grand écart entre deux moitiés du fichier	1,7 point
5. N'isole personne	Plus petit segment	549 utilisateurs
6. Aucune donnée de santé	Variables utilisées	âge et temps passé par jour

< 04 · La segmentation />

PLACER UN NOUVEL UTILISATEUR : DEUX INFORMATIONS SUFFISENT

Le segment ne dépend que de l'**âge** et du **temps passé par jour**, connus pour tous les utilisateurs : la fonction **assigner_segment** du notebook et le simulateur de l'application le calculent aussitôt.

Utilisateur fictif	Segment	Stress élevé dans le segment
16 ans · 250 min par jour	S5 Intensif · 13–17 ans	43,9 % · mineur
30 ans · 250 min par jour	S5 Intensif · 18–34 ans	51,7 %
60 ans · 250 min par jour	S5 Intensif · 55–65 ans	78,0 %
60 ans · 90 min par jour	S3 Modéré · 55–65 ans	15,2 %

< 05 · Protection des données · RGPD />

CIBLER SUR L'USAGE ET L'ÂGE, JAMAIS SUR LA SANTÉ

Sur quelles variables les segments peuvent-ils reposer ?

Le temps passé par jour et l'âge, uniquement.

- Santé et bien-être exclus (stress, bonheur, sommeil…) : données sensibles, article 9 du RGPD.
- Autres variables de profil exclues (genre, revenu, pays…) : elles n'apportent rien, et le RGPD impose de ne traiter que le nécessaire.

Un segment peut-il révéler quelque chose sur la santé ?

Oui : 95 % de stress élevé en S6 · 55–65 ans.

- 4 segments sur 24 dépassent 80 % (20 % des utilisateurs).
- Conditions : segments nommés par l'usage, aucun score de stress stocké, usage réservé aux outils de protection, sans publicité.

< 05 · Protection des données · RGPD />

LES MINEURS, ET NOS GARANTIES

Les règles pour les moins de 18 ans

- **Royaume-Uni :** le code de l'ICO demande que le profilage des enfants soit désactivé par défaut, sauf raison impérieuse dans leur intérêt.
- **Union européenne :** le DSA (article 28) interdit la publicité fondée sur le profilage d'un mineur.
- **Notre position :** pour les 13–17 ans, uniquement des protections activées par défaut (rappel de temps, mode sommeil).

Les mesures que nous appliquons

- Aucune donnée individuelle, aucun groupe de moins de 100 utilisateurs affiché.
- Données brutes jamais publiées : le dossier data/ est exclu du dépôt du projet.
- Interdiction écrite d'utiliser les segments pour la publicité.
- Utilisateurs informés, traitement inscrit au registre, analyse d'impact avant tout déploiement.

< 06 · Les limites />

CE QUE NOS DONNÉES NE PERMETTENT PAS D'AFFIRMER

Pas de cause à effet

Ce sont des corrélations : les personnes stressées pourraient aussi passer plus de temps sur l'application. Seule une expérience peut tester une cause.

Un panel de volontaires

Le stress et le bonheur ne viennent que des volontaires de l'étude bien-être, qui ne ressemblent pas forcément à l'ensemble des utilisateurs.

Une réplique synthétique

Le temps passé y explique 71 % du stress, contre 0,4 % au plus dans les études réelles ; le sommeil et le sport n'y ont aucun effet ; le lien caché entre stress et bonheur est très probablement artificiel.

Autres points de prudence : 26 % de lignes incohérentes, signalées ; le seuil de stress élevé (27) est une convention de lecture, pas un diagnostic ; « story privée » et « partages » n'existent pas dans le fichier.

< 07 · Recommandations />

TROIS RECOMMANDATIONS POUR LES ÉQUIPES PRODUIT

01

Un rappel de temps cumulé, selon l'âge

À l'entrée de S3 (≈ 1 h 30 par jour) pour les 55–65 ans, de S4 (≈ 3 h) pour les autres ; activé par défaut pour les mineurs ; compté sur toute la journée.

02

Le temps quotidien, indicateur n° 1

Suivi par segment dans les tableaux de bord, plutôt que les compteurs d'activité ou le score d'engagement ; stress et bonheur suivis séparément.

03

Des segments réservés à la protection

Rappels et mode sommeil uniquement : jamais de publicité, des segments nommés par l'usage et non par le stress, une analyse d'impact avant tout déploiement.

< En une phrase />

Plus on passe de temps sur Instagram, plus on est stressé, et ce lien est plus fort chez les plus âgés ; une segmentation simple par temps passé et âge permet aux équipes produit de cibler leurs outils de protection, sans utiliser de données de santé.

MERCI - VOS QUESTIONS ?_

Application : notebookinstagramfinal.streamlit.app · Notebook et code : dépôt D-DAT-700-MPL-7-1-data_rush4-1