{EPITECH}

BOOTCAMP DATA_

< RUSH 4 - SEGMENTATION DES UTILISATEURS />



BOOTCAMP DONNÉES

Introduction

Les réseaux sociaux sont sous pression pour prouver qu'ils ne nuisent pas à leurs utilisateurs. Les régulateurs posent des questions, la presse publie des études, et les annonceurs ne veulent pas être associés à une plateforme qui rend les gens malheureux. Le département d'Innovation d'Instagram veut sa propre réponse, basée sur ses propres données, avant que quelqu'un d'autre n'en fournisse une.

Votre rôle

Contexte

Le département d'Innovation d'Instagram a engagé votre équipe pour étudier le lien entre la façon dont les gens utilisent la plateforme et leur bien-être. Le département a deux objectifs. Tout d'abord, mesurer si et comment l'utilisation se rapporte à des indicateurs tels que le stress, le sommeil et le bonheur. Deuxièmement, comprendre les différents types d'utilisateurs sur la plateforme, afin que les équipes produits puissent concevoir des fonctionnalités pour chacun d'eux.

Les informations de bien-être et de santé proviennent d'un panel de recherche opt-in: des utilisateurs qui ont accepté de participer à une étude de bien-être, et dont les réponses auto-déclarées étaient reliées à leur compte. Le reste de chaque enregistrement — activité sur l'application et informations de profil — est conservé pour chaque utilisateur d'Instagram. Le département présentera vos conclusions à la direction d'Instagram. Tout ce que vous affirmez sera contesté.

Objectif

Fournir une segmentation des utilisateurs d'Instagram fondée sur leur utilisation, expliquer comment l'utilisation se rapporte au bien-être et être utilisable par les équipes produit. Défendez-la devant un jury.

Logistique

Article	Détail
Groupe	5 personnes
Durée	5 jours
Outils	Python ou R, dans un notebook
Données	Deux extraits de 200 000 utilisateurs chacun

{EPITECH}

Attentes

Les données

Les consultants externes ne voient jamais de vrais utilisateurs. L'équipe de confidentialité d'Instagram vous a donné une réplique synthétique du panneau : des utilisateurs artificiels générés pour reproduire la structure statistique que l'équipe a choisi de préserver. Cependant, vos recommandations seront appliquées à de vrais utilisateurs.

Le département a envoyé deux versions de la réplique : l'une d'elles est passée par une étape de nettoyage que l'équipe de confidentialité n'a pas documentée. Elles ne sont pas entièrement d'accord entre elles. Laquelle vous faites confiance, sur quels champs, c'est votre decision, et cela doit être documenté.

Cadre

Personne ne vous a dit ce qu'est une bonne segmentation. Définir les critères selon lesquels votre segmentation doit être évaluée et montrer qu'elle les respecte fait partie de ce qui est évalué. Au moins certains de ces critères doivent être vérifiables sur les données.

Vous pouvez construire vos segments en prédisant un indicateur de bien-être à partir de l'utilisation, en regroupant les utilisateurs en profils, ou les deux. Quelle que soit la voie choisie, le résultat doit être des segments, et vous devez expliquer pourquoi votre approche répond mieux à la question du département que l'alternative. Seuls les membres du panneau disposent des données de bien-être, mais les équipes produit voudront placer chaque utilisateur dans un segment : vos segments doivent pouvoir être attribués à tout utilisateur des données qu'Instagram détient sur chaque utilisateur, et le carnet doit démontrer comment un nouvel utilisateur serait attribué.

Ce que la segmentation doit ajouter

Le département sait déjà que certains utilisateurs passent beaucoup plus de temps sur l'application que d'autres. Votre segmentation doit montrer ce que cela leur dit que le classement des utilisateurs par le temps passé ne révèle pas — ou démontrer, avec des preuves, que rien de plus ne peut être dit. Il en va de même pour le bien-être : un indicateur qui s'avère sans lien avec l'utilisation est une constatation.

Les extraits bruts décrivent ce que font les utilisateurs, colonne par colonne. Les variables que vous construisez à partir d'eux doivent être justifiées par ce qu'elles apportent aux données, et non par l'histoire qu'elles racontent.



Les conclusions doivent indiquer ce que les données ne permettent pas d'affirmer, y compris tout ce qui concerne la causalité, tout ce qu'un panel de bénévoles ne peut pas dire sur tous les utilisateurs, et tout ce qu'une réplique synthétique ne peut pas dire sur les vrais utilisateurs.



Certaines méthodes ne se scalent pas à 200 000 utilisateurs.

Protection des données

Les membres du panel ont accepté une étude sur le bien-être. Les équipes produit veulent désormais utiliser vos segments pour cibler des fonctionnalités auprès des utilisateurs, ce qui n'est pas la même chose. Pour les utilisateurs dans l'Union européenne et au Royaume-Uni, y compris les utilisateurs de moins de 18 ans, vos livrables doivent prendre position sur ce qui est légalement possible et dans quelles conditions : sur quelles variables vos segments peuvent être construits s'ils doivent être utilisés pour le ciblage, et si placer un utilisateur dans un segment peut révéler à lui seul quelque chose sur sa santé.

L'équipe de confidentialité ne peut pas garantir que le générateur n'a jamais reproduit un utilisateur réel. Le cahier livré ne doit afficher aucun dossier d'utilisateur individuel, ni aucun résultat qui isole une poignée d'utilisateurs.

Défense

Votre équipe présente son travail en 15 minutes à un jury composé de la direction d'Instagram, suivi de 10 minutes de questions. Le jury posera des questions auxquelles vous n'avez pas préparé.



Chaque membre de l'équipe doit être capable de répondre à des questions sur n'importe quelle partie du travail. Une défense divisée en cinq monologues indépendants ne montre pas le résultat de l'équipe.

Livrables

Livrable	Contenu
Cahier	Choix de données, exploration, ingénierie des caractéristiques, segmentation, évaluation par rapport à vos critères, limites, protection des données
diapositives de défense	Support pour la présentation de 15 minutes
Défense orale	15 minutes de présentation, 10 minutes de questions

Le cahier doit fonctionner du haut vers le bas sur les extraits fournis et produire chaque résultat montré dans la défense, identiquement à chaque exécution.

Le dépôt du groupe fait partie des livrables : son historique doit montrer comment le travail a été partagé, et son README doit indiquer qui était responsable de quoi.

Ressources

Les deux extraits sont disponibles dans les ressources étudiantes du module (`rush-4/`).

{EPITECH}

v 2.0.1

